

OrquestraCX

Camada de orquestração inteligente para atendimento omnichannel

O cliente que troca de canal não deveria recomençar do zero. O OrquestraCX observa a conversa em todos os canais, mede a fricção acumulada em tempo real e transfere para um atendente humano *antes* que o cliente precise pedir — levando junto todo o histórico.

VÍDEO DE APRESENTAÇÃO

Demonstração da solução

<https://www.youtube.com/watch?v=8g-8A9QrEvI>

Assistir no YouTube

FASE	BACKEND	FRONTEND	COBERTURA
MVP funcional persistência em memória	Python 3.11+ FastAPI · Pydantic v2	React 18 · Vite Tailwind CSS v4	61 testes 100% aprovados

INTEGRANTES · TURMA 4SIT-2026

551268	Gustavo Matos dos Santos	552528	Leonardo Franco de Oliveira
98342	Heitor Novaes dos Santos	551548	Pablo Samuel Rangel Quilaqueo Aguayo
552006	Enzo Gabriel Nascimento Campos		

O problema

Uma operadora atende o mesmo cliente por vários canais, e cada canal enxerga apenas a si mesmo. O cliente abre o aplicativo, não resolve, migra para o WhatsApp — e o atendimento recomeça do zero. Ele repete o CPF, repete o problema, repete a frustração. Quando finalmente chega a um humano, já está exausto, e o atendente recebe uma conversa sem passado.

Há duas perdas simultâneas: o **contexto**, que se dissolve na fronteira entre canais, e o **tempo**, porque ninguém percebe que aquele cliente específico já passou do ponto muito antes de ele escrever "quero falar com uma pessoa".

A TESE DO PRODUTO

A insatisfação é observável antes de ser declarada. Repetir a mesma pergunta, reformular a demanda, migrar de canal, escrever em caixa alta — são sinais mensuráveis. Somados, antecipam a ruptura. O OrquestraCX transforma esses sinais em um número único, o **Score de Fricção**, e age quando ele cruza um limiar.

Arquitetura da solução

O sistema é uma camada de orquestração entre os canais de entrada e o painel do atendente. Os canais falam formatos diferentes — o aplicativo envia um `usuario_id`, o WhatsApp envia um envelope de webhook com telefone — e ambos são traduzidos para um único caso de uso interno.




FIGURA 1 Componentes e sentido das chamadas. O Orquestrador é o único ponto que conhece o fluxo completo; os quatro serviços resolvem uma pergunta cada e não se chamam entre si. Nenhum serviço enxerga o banco: todos falam com as interfaces de repositório, e é por isso que a coluna de persistência pode ser trocada inteira sem tocar no domínio.

Fluxo de uma mensagem

Toda mensagem, venha de qual canal vier, percorre a mesma sequência. O passo 2 é o que sustenta a proposta de valor: se existe sessão viva para aquele cliente, o protocolo é reaproveitado — mesmo que a mensagem tenha chegado por outro canal.



FIGURA 2 Os oito passos do processamento. O ramo do handoff ocorre uma única vez por atendimento: depois de transferido, o bot deixa de responder por intenção, porque a conversa passou a pertencer a uma pessoa.

Continuidade de contexto

É aqui que o produto se diferencia. O WhatsApp conhece o cliente por um número de telefone; o aplicativo, por um identificador de login. Sem uma identidade canônica que ligue os dois, cada canal abre o seu próprio protocolo e a conversa anterior desaparece.



FIGURA 3 A diferença que o produto introduz. Cada cliente tem um `cliente_id` canônico e um mapa de identificadores por canal; enquanto a sessão estiver viva, qualquer canal escreve no mesmo protocolo. A migração deixa de ser uma perda e passa a ser um sinal medido.

Motor de Score de Fricção

Cada turno do cliente passa por nove detectores independentes. Todo detector que dispara devolve um peso e uma justificativa em português, gravada como evento imutável — o atendente vê não apenas o número, mas por que ele chegou lá.

SINAIS E PESOS

SINAL	PESO	DISPARA QUANDO
Pedido de humano	+25	o cliente pede um atendente explicitamente
Repetição	+18	reenvia o mesmo texto ou reformula a mesma demanda
Troca de canal	+16	migra de canal mantendo o assunto
Sentimento negativo	+6 a +20	léxico de insatisfação, proporcional à intensidade
Intenção repetida	+12	três turnos no mesmo assunto sem solução
Loop sem resolução	+8 / turno	passa de quatro turnos com o bot (teto +24)
Impaciência	+8	três mensagens em menos de 60 segundos
Caixa alta	+5	60% ou mais da mensagem em maiúsculas
Decaimento	-12	um atendente humano assume a conversa

O gráfico abaixo é a jornada real registrada pelo sistema, não uma ilustração. O handoff dispara no quarto turno, quando a cliente escreve *"já expliquei isso três vezes, isso é um absurdo"* — **um turno antes** de ela pedir um atendente. O sistema se antecipou ao pedido.




FIGURA 4 Trajetória real do score na jornada de Ana Beatriz Souza. Cada barra é o acréscimo de um turno; a cor indica a faixa alcançada — **ESTÁVEL** **ATENÇÃO** **CRÍTICO**. O turno 5, já depois da transferência, apenas satura o score em 100.

OS MESMOS DADOS, EM TABELA

TURNO	CANAL	SCORE	Δ	FAIXA	SINAIS DETECTADOS
1	App Claro	0	—	ESTÁVEL	nenhum
2	App Claro	18	+18	ESTÁVEL	repetição +18
3	WhatsApp	54	+36	ATENÇÃO	troca de canal +16 · intenção repetida +12 · impaciência +8
4	WhatsApp	82	+28	CRÍTICO · HANDOFF	sentimento negativo +20 · impaciência +8
5	WhatsApp	100	+18	CRÍTICO	pedido de humano +25 · caixa alta +5 · loop +8

Funcionalidades

ENTRADA

Recepção multicanal com tradução de formato

Dois endpoints recebem mensagens em formatos distintos: o aplicativo envia identificador de login, versão e dispositivo; o WhatsApp envia um envelope de webhook com telefone e identificador de mensagem. Ambos são convertidos para uma única chamada interna, e é por isso que acrescentar um terceiro canal — uma URA, um chat no site — custa cerca de quinze linhas na camada de rotas e nada no domínio.

IDENTIDADE

Resolução de cliente entre canais

Cada cliente tem um `cliente_id` canônico e um mapa de identificadores por canal. O telefone `5511998877321` e o login `user_ana` apontam para a mesma pessoa, e é essa tradução que permite reconhecer, no primeiro contato pelo WhatsApp, que aquela conversa começou no aplicativo vinte minutos antes.

CLASSIFICAÇÃO

Detecção de intenção por regras ponderadas

Um classificador léxico determinístico atribui a mensagem a uma de sete intenções — suporte técnico, financeiro, contestação de fatura, segunda via, planos, cancelamento ou não classificada. Cada termo tem peso, e a confiança combina o quanto a intenção vencedora se destaca das concorrentes com a força absoluta da evidência encontrada.

A escolha por regras em vez de um modelo estatístico foi deliberada: roda em microssegundos, o que ajuda no requisito de resposta abaixo de dois segundos, e é inteiramente explicável — o painel consegue mostrar quais termos levaram àquela classificação.

MEDIÇÃO

Score de Fricção com trilha de auditoria

Nove detectores avaliam cada turno e o score acumula entre 0 e 100. Dois merecem destaque. O de **repetição** reconhece duas formas de repetir: o reenvio quase literal e a reformulação — quando o cliente reescreve a mesma demanda com outras palavras, geralmente mais curto. A comparação de texto inteiro perde esse segundo caso porque penaliza diferença de comprimento, então o sistema também mede a sobreposição de palavras de conteúdo.

O de **troca de canal** registra o canal anterior, não o de origem — numa jornada que vai do aplicativo ao WhatsApp e volta, dizer "App Claro → App Claro" seria falso. Cada sinal detectado vira uma linha imutável com peso, score resultante e descrição legível.

DECISÃO

Handoff antecipado com contexto consolidado

Ao cruzar 70, o atendimento entra na fila com status de espera por humano e o bot para de responder por intenção — seria errado o robô insistir em algo já escalado para uma pessoa. O atendente recebe o histórico completo dos dois canais, a intenção consolidada, a trajetória do score e a lista de sinais que motivaram a transferência. O disparo acontece uma única vez por atendimento.

OPERAÇÃO

Painel do atendente

Três colunas: a fila ordenada por score, a conversa unificada com marcação visual do ponto exato em que o cliente trocou de canal, e o painel de inteligência com o medidor de fricção, a intenção detectada e o histórico de sinais. A atualização é por consulta periódica a cada três a quatro segundos, com proteção contra requisições sobrepostas, pausa quando a aba está oculta e recuo progressivo em caso de erro.

Quando o atendente responde, o score cai doze pontos e a resposta aparece no aplicativo do cliente na consulta seguinte.

DEMONSTRAÇÃO

Simuladores de canal

Duas telas reproduzem o aparelho do cliente — o aplicativo da Claro e o WhatsApp — permitindo demonstrar a continuidade de contexto ao vivo, sem depender de canais reais. As sugestões de resposta são contextuais: evoluem conforme a intenção detectada e o estágio da conversa, conduzindo naturalmente da abertura da demanda até a escalada que provoca o handoff.

Desacoplamento e migração

A arquitetura final prevê Redis para sessão, MongoDB para histórico conversacional e PostgreSQL para dados estruturados e auditoria. Esta fase entrega o MVP com estruturas em memória — mas modeladas no formato de destino, para que a troca não exija reescrita.




FIGURA 5 Regra de dependência e ponto de troca. Todos os métodos de repositório já são assíncronos, ainda que hoje sejam dicionários — é o que permite plugar `redis.asyncio`, `motor` e `asyncpg` sem alterar nenhuma assinatura nos serviços. A migração para a fase 2 altera quatro linhas de `dependencies.py`.

REPOSITÓRIO	FASE 1 (ATUAL)	FASE 2	CHAVE / ESQUEMA
Sessão	dicionário com expiração preguiçosa	Redis	sessao:{cliente_id} · TTL 1800 s
Conversa	lista por protocolo	MongoDB	um documento por protocolo
Cliente	dicionário com índice secundário	PostgreSQL	UNIQUE(canal, identificador)
Atendimento	dicionário e lista de eventos	PostgreSQL	atendimentos + eventos_friccao

Evidências de execução

61 TESTES APROVADOS	0,76ms LATÊNCIA MÁXIMA MEDIDA	2000ms ORÇAMENTO DO REQUISITO	7 ENDPOINTS REST
---	---	---	--

O requisito não funcional de resposta abaixo de dois segundos é verificado por teste automatizado a cada execução. As medições reais ficam entre 0,39 ms e 0,76 ms — três ordens de grandeza de folga, resultado de manter o NLP determinístico e a avaliação de fricção em memória.

A suíte cobre o classificador de intenção, cada um dos nove detectores de fricção, a saturação e os limiares do score, a continuidade entre canais em jornadas de ida e volta, o disparo único do handoff e o payload completo do painel. Os testes são também a rede de segurança da migração: se continuarem passando depois da troca por bancos reais, a lógica de negócio não mudou.

Decisões que a suíte protege

- **A intenção consolidada não é sobrescrita por uma classificação vazia.** Um turno final como "QUERO UM ATENDENTE" não carrega assunto de negócio; se sobrescrevesse, apagaria "Contestação de Fatura" exatamente no payload que o atendente vai ler. Esse defeito existiu no código e foi encontrado por um teste.
- **O limiar mora em um lugar só.** A faixa de fricção é derivada unicamente no serviço; a entidade não replica os valores 40 e 70, para não haver dois pontos de calibração e um deles ser esquecido.
- **O handoff não redispara.** Depois de transferido, novos sinais continuam elevando o score e alimentando a auditoria, mas não reabrem a transferência.

Vídeo de apresentação

A gravação percorre a jornada completa: a cliente inicia o contato pelo aplicativo, migra para o WhatsApp, o score cruza o limiar, o handoff dispara e o atendente assume a conversa já com todo o histórico consolidado à frente.

LINK DE ACESSO

Assistir à demonstração

<https://www.youtube.com/watch?v=8g-8A9QrEvI>

Assistir no YouTube

OrquestraCX · Challenge FIAP + Claro 2026 · Turma 4SIT-2026 · Documento de arquitetura da solução. Fase 1: MVP funcional com persistência em memória, modelada para migração a Redis, MongoDB e PostgreSQL.